

UACM
Universidad Autónoma
de la Ciudad de México
NADA HUMANO ME ES AJENO

UNIVERSIDAD AUTÓNOMA DE LA CIUDAD DE MÉXICO

Avance 1 de proyecto final

Integrantes:

Francisco Aramis Alcántara Vivas 11-003-1206

Pérez Nava Brayan 21-003-0254

Marcial Espinoza Joseline Ariana 22-003-0552

Profesora:

Araceli Liliana Reyes

Materia:

Inteligencia de Negocios

Índice

3.1. Identificación del proyecto ... 3
Significado de los términos principales ... 3
3.2. Problema organizacional y decisión ... 4
Contexto ... 4
Problema principal ... 4
Actores ... 4
Decisión ... 4
Alcance ... 5
3.3. Pregunta de negocio ... 5
Pregunta principal ... 5
Relación entre la pregunta y los datos ... 6
3.4. Justificación del uso de BI ... 6
3.5. Dataset seleccionado y fuente alternativa ... 7
Fuente seleccionada ... 7
Fuente alternativa ... 7
3.6. Inventario y primera lectura de los datos crudos ... 9
Inventario de archivos o tablas ... 9
Qué representa cada fila de la hoja principal ... 9
Inventario de columnas ... 10
Problemas visibles y dudas iniciales ... 11
3.7. Plan analítico preliminar ... 12
Ejemplo de cómo se calcula el margen (los números son inventados, solo sirven para explicar) ... 13
Preguntas analíticas secundarias ... 13
3.8. Arquitectura propuesta de la cadena BI ... 14
3.9. Riesgos, límites y dudas abiertas ... 15
Preguntas que hay que hacerle a alguien que conozca el proceso ... 15
3.10. Conclusión de viabilidad y siguientes pasos ... 15
Siguientes pasos (semanas 5 a 8) ... 16
Anexo A. Lista completa de columnas de la hoja Ventas Supermercado ... 17

Avance 1: Problema, Datos y Plan Analítico

Proyecto: SuperMarketMundial

3.1. Identificación del proyecto

Nombre del equipo: Equipo BI SuperMarket.

Nombre provisional del proyecto: SuperMarketMundial.

Integrantes del equipo:

Francisco Aramis Alcántara Vivas (11-003-1206)

Pérez Nava Brayan (21-003-0254)

Marcial Espinoza Joseline Ariana (22-003-0552)

Fecha de entrega: 21 de septiembre de 2026

Versión corregida.

La fuente seleccionada para el proyecto se encuentra en el siguiente enlace: https://github.com/RodrigoAyalaDA/Analisis-Ventas-Excel

El repositorio del proyecto está disponible en:

https://github.com/Kaedee2/Proyecto-superMarketGlobal-BI.git

Descripción del proyecto: SuperMarketMundial aplica descuentos en casi la mitad de sus ventas (47.8 % en los cuatro mercados que se analizan) sin conocer el punto exacto en que estos dejan de ser rentables. El proyecto analizará cómo varía la utilidad según el nivel de descuento, la categoría y la subcategoría del producto, el mercado y el mes, para definir límites de descuento que eviten pérdidas y apoyen decisiones de marketing y logística.

Significado de los términos principales

Término	Significado
Línea de pedido	Es un producto dentro de un pedido. Por ejemplo, si un cliente compra una silla y una lámpara en el mismo pedido, equivale a 2 líneas de pedido, una por cada producto. Cada fila del Excel es una línea de pedido.
Ventas	Es el dinero que pagó el cliente por un producto de su pedido, con el descuento ya aplicado.
Utilidad	Es lo que gana la tienda en una venta después de restar lo que le costó el producto. Si la utilidad es negativa, la tienda perdió dinero en esa venta. El dataset no aclara si a esta cantidad ya se le restó el costo de envío.
Descuento	Es el porcentaje que se le rebaja al precio del producto. En el Excel aparece como número decimal, por ejemplo, 0.2 quiere decir 20 % de descuento.
Margen	Indica qué parte de lo vendido se convierte en ganancia. Se calcula dividiendo la utilidad entre las ventas y multiplicando por 100. Por ejemplo, si se vendieron $100 y la utilidad fue de $10, el margen es de 10 %.

Término	Significado
Tramo de descuento	Es un grupo de descuentos parecidos. Las ventas se agrupan en siete tramos (0 %, de 1 a 10 %, de 11 a 20 %, de 21 a 30 %, de 31 a 40 %, de 41 a 50 % y más de 50 %) para comparar el margen de cada grupo.
Mercado	Es la zona comercial a la que pertenece la venta. El archivo tiene siete mercados y el análisis usa cuatro de ellos, que son Estados Unidos, Latinoamérica, Europa y Asia-Pacífico.

3.2. Problema organizacional y decisión

Contexto

SuperMarketMundial es una cadena de supermercados con operaciones en varias regiones y países. El área de Marketing y Logística aplica descuentos como estrategia para incrementar ventas, pero no tiene claridad sobre el impacto real de estos descuentos en la rentabilidad.

Problema principal

En los cuatro mercados analizados, la empresa da descuentos en casi la mitad de sus ventas (47.8 %), pero no tiene claro hasta qué porcentaje puede descontar sin perder dinero. Tampoco sabe si ese descuento máximo debería ser diferente según el tipo de producto (categoría y subcategoría) o el mercado, lo que provoca pérdidas que pasan desapercibidas.

Lo que confirman los datos es que existen registros de descuento, venta y utilidad, y que casi una de cada cuatro ventas (24.2 %) genera pérdidas. Lo que planteamos como supuesto para este proyecto es que la empresa no conoce cuál es su límite de descuento rentable.

Actores

Gerencia de Marketing: decide qué descuentos aplicar por categoría.

Gerencia de Logística: evalúa costos de envío y su impacto en la rentabilidad.

Analista de BI: transforma los datos en información para la decisión.

Decisión

Fijar un límite máximo de descuento diferenciado por subcategoría de producto y mercado, para que la empresa deje de vender con pérdida. También se quiere revisar si conviene dar menos descuento en los meses en que se vende más. Los datos solo registran las ventas que sí ocurrieron, por lo que no permiten saber cuántas ventas se perderían si el descuento fuera menor. Por eso la decisión se enfoca en evitar pérdidas y no en aumentar el volumen de ventas.

Alcance

- Población: cada producto vendido dentro de un pedido. Si un cliente compra tres productos en un mismo pedido, el archivo registra tres filas.
- Proceso: aplicación de descuentos y su efecto en la utilidad.
- Mercados: Estados Unidos (US), Latinoamérica (LATAM), Europa (EU) y Asia-Pacífico (APAC). Se eligieron porque tienen una cantidad de ventas parecida, entre 9,730 y 11,001 cada uno. EMEA (5,300 ventas), África (4,587) y Canadá (384) quedan fuera porque tienen muchas menos ventas y no se compararían en igualdad de condiciones.
- Periodo: de enero de 2011 a diciembre de 2014. Los resultados se revisarán mes por mes.
- Queda fuera: costos de adquisición, inventario, gastos operativos detallados y promociones específicas.

3.3. Pregunta de negocio

Pregunta principal

¿A partir de qué nivel de descuento la venta deja de ser rentable, y ese punto es el mismo en todas las categorías, subcategorías y mercados?

Estructura de la pregunta:

- Fenómeno o medida: nivel de descuento y rentabilidad (utilidad).
- Población o proceso: cada producto vendido en los cuatro mercados.
- Comparación o periodo: por categoría, subcategoría, mercado y mes, de 2011 a 2014.
- Decisión que apoya: fijar límites de descuento por subcategoría y mercado.

N.	Subpregunta	Datos que usa	Respuesta que busca
1	¿Cómo cambia el margen de ganancia conforme aumenta el descuento?	Descuento, Ventas, Utilidad	Identificar el punto donde el margen se vuelve cero o negativo
2	¿Ese límite es el mismo para todas las categorías y subcategorías?	Categoría, Subcategoría, Descuento, Ventas, Utilidad	Comparar el límite entre categorías y subcategorías
3	¿Ese límite es el mismo en todos los mercados?	Mercado, Descuento, Ventas, Utilidad	Comparar el límite entre mercados
4	¿Qué porcentaje de ventas se realiza con descuentos mayores al límite y cuánto dinero se pierde?	Descuento, Ventas, Utilidad	Cuantificar el impacto de los descuentos excesivos

N.	Subpregunta	Datos que usa	Respuesta que busca
5	¿Cómo cambian las ventas, los descuentos y las pérdidas mes a mes?	Fecha Salida (mes), Descuento, Ventas, Utilidad	Saber si conviene dar menos descuento en los meses en que se vende más

Relación entre la pregunta y los datos

La siguiente tabla revisa si el archivo tiene la información que necesita la pregunta.

Elemento	Respuesta del equipo
Problema de información	En los cuatro mercados se aplica descuento en el 47.8 % de las ventas, pero no se sabe a partir de qué descuento las ventas empiezan a dejar pérdida ni si ese punto es igual en todas las subcategorías y mercados.
Decisión que se busca apoyar	Fijar un descuento máximo para cada subcategoría en cada mercado.
Columnas necesarias	Descuento, Ventas, Utilidad, Categoria, Subcategoria, Mercado, Fecha Salida y Costo Envío.
Columnas disponibles	Todas vienen en la hoja Ventas Supermercado y ninguna tiene datos vacíos.
Información que falta	El archivo no tiene el costo de compra de cada producto, los gastos de operación de la empresa ni la moneda de los montos. Tampoco dice cuánto se habría vendido sin descuento. Por eso la pregunta se limita a encontrar en qué punto las ventas dejan pérdida.
Resultados que se esperan	Una tabla con el margen de cada tramo de descuento y el tramo a partir del cual el margen se vuelve negativo, separada por subcategoría, mercado y mes.

3.4. Justificación del uso de BI

La situación se beneficia de un sistema de Inteligencia de Negocios porque:

- Datos transformables en información útil: miles de transacciones con descuentos, utilidad y mercado pueden convertirse en indicadores claros.
- Comparaciones necesarias: se requieren comparaciones recurrentes entre categorías, subcategorías, mercados y niveles de descuento.
- Reproducibilidad y trazabilidad: el proceso debe ser reproducible para actualizar el análisis periódicamente.
- Periodicidad: el análisis tendría sentido actualizarse mensual o trimestralmente.
- Mejora frente a archivos aislados: sin un flujo BI, revisar archivos de Excel o cifras sin definición común no permite identificar el punto de rentabilidad de forma confiable.

3.5. Dataset seleccionado y fuente alternativa

Fuente seleccionada

Criterio	Respuesta
Nombre	Ventas Supermercado – Rodrigo Ayala
Enlace exacto	https://github.com/RodrigoAyalaDA/Analisis-Ventas-Excel
Plataforma	GitHub
Autor o institución	Rodrigo Ayala publicó el archivo en GitHub. Los datos son los mismos de Global Superstore, una base de ejemplo creada por Tableau, que sería el productor original.
Fecha de consulta	15 de septiembre de 2026
Versión o actualización	No especificada
Formatos	Excel (.xlsx) con seis hojas, que son Guía del Archivo, Dashboard, Analisis, Ventas Supermercado, Regiones y Productos
Número de archivos	1
Tamaño aproximado	20.2 MB
Filas y columnas	51,290 registros × 35 variables en la hoja principal. La hoja Regiones tiene 152 filas y la hoja Productos tiene 10,768
Licencia	No se especifica.
Metadatos y diccionario	No hay diccionario de datos.
Cobertura temporal	De 2011 a 2014, según la fecha de venta.
Cobertura geográfica	147 países agrupados en 7 mercados. El análisis usa 4 de ellos, que son Estados Unidos, Latinoamérica, Europa y Asia-Pacífico
Unidad de observación	Línea de pedido, es decir, un producto dentro de un pedido
Variables relevantes	Descuento, Ventas, Utilidad, Categoría, Subcategoría, Mercado, País, Fecha Salida
Limitaciones	Licencia no especificada, falta de metadatos, posible ambigüedad en moneda. No se sabe si a la utilidad ya se le restó el costo de envío
Cobertura poblacional	Clientes de tres segmentos, que son Consumer (personas), Corporate (empresas) y Home Office (oficinas en casa)
Datos personales o sensibles	Trae el nombre y el ID de cada cliente.
Viabilidad	Alta: formato Excel, estructura tabular, muchas variables

Fuente alternativa

Criterio	Respuesta
Nombre	Sample Superstore

Criterio	Respuesta
Enlace exacto	https://www.kaggle.com/datasets/vivek468/superstore-dataset-final
Plataforma	Kaggle
Productor original	Tableau. Kaggle solo es la plataforma donde se publicó
Fecha de consulta	15 de septiembre de 2026
Versión o actualización	No especificada
Formatos	CSV
Número de archivos	1
Tamaño aproximado	~2.5 MB
Filas y columnas	~10,000 filas × 21 columnas
Licencia	Open Database License (ODbL)
Metadatos y diccionario	Sí, disponibles en la página de Kaggle
Cobertura temporal	2014–2017
Cobertura geográfica	Estados Unidos
Cobertura poblacional	Clientes de segmentos Consumer, Corporate y Home Office
Unidad de observación	Línea de pedido (producto dentro de un pedido)
Granularidad	Transacción individual
Variables relevantes	Discount, Profit, Sales, Category, Sub-Category, Region, Order Date
Limitaciones	Solo EE.UU.; no incluye costo de adquisición
Datos personales o sensibles	Nombres de clientes
Viabilidad con Python, PostgreSQL, SQL y Power BI	Alta en lo técnico. Es un CSV pequeño y ordenado que se puede cargar sin problema en Python, PostgreSQL y Power BI. Se descarta por otra razón, que es que solo tiene ventas de Estados Unidos.

Criterio	Fuente alternativa (Kaggle)	Fuente seleccionada (GitHub)
Relación con la pregunta	Media. Tiene descuento, ventas y utilidad, pero solo de Estados Unidos, así que no permite comparar mercados	Alta: incluye descuento, ventas, utilidad, categoría, subcategoría, mercado, país y fecha de venta
Formato y tamaño	CSV, ~10,000 × 21	Excel, 51,290 × 35
Licencia y procedencia	ODbL, Tableau/Kaggle	No especificada, GitHub
Metadatos y diccionario	Sí, completos	No especificados
Cobertura y granularidad	2014–2017, EE.UU., línea de pedido	2011–2014, 147 países, línea de pedido
Limitaciones y riesgos	Solo EE.UU.	Licencia no especificada, falta de documentación

Criterio	Fuente alternativa (Kaggle)	Fuente seleccionada (GitHub)
Decisión sobre la fuente	Descartar	Aceptar con cautela

Cierre de la comparación: Se elige la fuente de GitHub porque tiene más variables (35 vs 21), más registros (51,290 vs ~10,000), seis hojas y cobertura de varios países. La fuente de Kaggle se descarta porque solo tiene ventas de Estados Unidos, y la pregunta del proyecto necesita comparar varios mercados.

3.6. Inventario y primera lectura de los datos crudos

Inventario de archivos o tablas

El Excel tiene seis hojas, pero solo tres contienen datos que sirven para responder la pregunta. La siguiente tabla describe cada una.

Hoja	Filas y columnas	Formato	Qué representa cada fila	Cobertura	Para qué sirve
Ventas Supermercado	51,290 filas y 35 columnas	Tabla de datos	Un producto dentro de un pedido	Ventas de 2011 a 2014 en 147 países	Es la tabla principal del análisis
Regiones	152 filas y 3 columnas	Tabla de datos	Un país	147 países. Cinco aparecen dos veces	Dice a qué mercado y región pertenece cada país
Productos	10,768 filas y 4 columnas	Tabla de datos	Un producto	10,292 productos.	Dice la categoría y la subcategoría de cada producto
Guía del Archivo	5 filas y 2 columnas	Texto	Una hoja del archivo	Las otras cinco hojas	Solo sirve como referencia, no se analiza
Analisis	1,592 filas y 46 columnas	Tablas dinámicas y gráficas	Resúmenes ya calculados	Resultados del autor del archivo	No se usa porque es un análisis hecho por otra persona
Dashboard	Vacía	—	—	—	No se usa porque no tiene datos

Qué representa cada fila de la hoja principal

Cada fila representa una línea de venta de un producto dentro de una transacción de venta. Una misma venta puede aparecer en varias filas si incluye varios productos. Cada observación contiene información del producto vendido, cliente, ubicación, descuento aplicado, ventas generadas y utilidad obtenida. Para identificar una fila se necesitan dos datos juntos, el ID Venta (el pedido) y el ID Producto (el producto), porque un mismo producto aparece en muchos pedidos distintos. En las 51,290 filas hay 25,086 pedidos y 10,292 productos diferentes.

Region	ID Producto	Categoria	Subcatego	Ventas	Descuento	Utilidad	Porcentaje de ganancias
Africa	OFF-TEN-10	Office Suppli	Storage	408,3	0,00 %	106,14	26,00 %
Oceania	OFF-SU-100	Office Suppli	Supplies	120,366	10,00 %	36,04	29,94 %
EMEA	OFF-TEN-10	Office Suppli	Storage	66,12	0,00 %	29,64	44,83 %
North	OFF-PA-100	Office Suppli	Paper	44,865	50,00 %	-26,06	-58,07 %
Oceania	FUR-FU-100	Furniture	Furnishings	113,67	10,00 %	37,77	33,23 %
Oceania	OFF-PA-100	Office Suppli	Paper	55,242	10,00 %	15,34	27,77 %
Central Asia	TEC-CO-100	Technology	Copiers	285,78	0,00 %	71,40	24,98 %
West	FUR-BO-100	Furniture	Bookcases	290,666	15,00 %	3,42	1,18 %
Africa	OFF-FEL-10	Office Suppli	Storage	206,4	0,00 %	92,88	45,00 %
North Asia	OFF-ST-100	Office Suppli	Storage	162,72	0,00 %	68,31	41,98 %
North Asia	OFF-AP-100	Office Suppli	Appliances	352,35	0,00 %	137,40	39,00 %
Central	OFF-AP-100	Office Suppli	Appliances	400,704	40,00 %	20,02	5,00 %
EMEA	FUR-ADV-10	Furniture	Furnishings	309,6	0,00 %	148,50	47,97 %
Central	OFF-AR-100	Office Suppli	Art	139,65	0,00 %	15,30	10,96 %
Central Asia	OFF-SU-100	Office Suppli	Supplies	40,68	0,00 %	11,79	28,98 %

Imagen 1. Algunas filas de la hoja Ventas Supermercado. La fila marcada en amarillo es una venta con 50 % de descuento que dejó pérdida. La última columna, Porcentaje de ganancias no viene en el archivo, la agregamos nosotros dividiendo la utilidad entre las ventas.

Inventario de columnas

La siguiente tabla muestra las columnas que más importan para la pregunta. La lista completa de las 35 columnas está en el Anexo A, al final del documento. Los rangos (el valor más bajo y el más alto) se calcularon con las 51,290 filas.

Columna	Tipo aparente	Significado o unidad	Ejemplo o rango	Duda o problema visible
Ventas	Numérica decimal	Importe total de la venta (moneda)	0.44 – 22,638.48	No se especifica la moneda.
Cantidad	Numérica entera	Número de unidades vendidas	1 – 14	Ninguno visible.
Descuento	Numérica decimal	Descuento aplicado a la venta	0 – 0.85 (de 0 % a 85 %)	El descuento viene en decimal (0.2 es 20 %). Hay 629 ventas con valores raros, como 0.202 o 0.602, todas de Latinoamérica, que podrían ser errores de captura.
Utilidad	Numérica decimal	Ganancia o pérdida obtenida	−6,599.98 – 8,399.98	No se explica cómo se calcula. Tampoco se sabe si ya tiene restado el costo de envío.
Ganancia	Categórica	Indica si hubo ganancia o pérdida	Ganancia, Pérdida	Solo dice si la utilidad fue positiva o negativa, así que repite información de la columna Utilidad.
Categoría	Categórica	Tipo general de producto	Furniture, Office Supplies, Technology	Ninguno visible.
Subcategoría	Categórica	Clasificación más específica	Storage, Paper, Copiers, Furnishings (17 en total)	Ninguno visible.

Columna	Tipo aparente	Significado o unidad	Ejemplo o rango	Duda o problema visible
Región	Categórica	Región geográfica de la venta	Africa, Oceania, West, Central	Todas las ventas de Estados Unidos (9,994) dicen West, aunque son de 49 estados distintos. Por eso no sirve para comparar zonas.
Mercado	Categórica	Mercado comercial	APAC, EU, US, LATAM, Africa, EMEA, Canada (7 en total)	Puede confundirse con Región. Es la columna que se usa para comparar zonas.
País	Texto	País donde se realizó la venta	Algeria, Australia, China (147 en total)	Ninguno visible.
Ciudad	Texto	Ciudad asociada a la venta	Stockholm, Budapest, Dhaka	Posibles diferencias de escritura.
Fecha Salida	Fecha	Fecha en que se realizó la venta	01/01/2011 – 31/12/2014	Ya viene en formato de fecha. Es el día de la venta y de aquí se obtiene el mes.
Fecha Entrega	Fecha	Fecha de entrega del pedido	03/01/2011 – 07/01/2015	Ya viene en formato de fecha. 286 entregas son de 2015 porque corresponden a pedidos de diciembre de 2014.
Días Transcurridos	Numérica entera	Días entre venta y entrega	0 – 7	Verificar que coincida con las fechas.
Método Envío	Categórica	Tipo de envío utilizado	Standard Class, First Class, Second Class	Ninguno visible.
Costo Envío	Numérica decimal	Costo del transporte	0 – 933.57	No se especifica moneda.

Problemas visibles y dudas iniciales

La tabla resume lo que se encontró al revisar el archivo completo. Cada dato es un conteo sobre las 51,290 filas de la hoja Ventas Supermercado.

Problema	Qué se encontró	Qué se hará
Datos vacíos	Ninguna de las 35 columnas tiene celdas vacías.	Nada
Filas duplicadas	No hay filas exactamente iguales en las 35 columnas.	Nada
Mismo producto dos veces en un pedido	76 filas (38 pares) tienen el mismo ID Venta y el mismo ID Producto, pero con cantidad, venta o costo de envío distintos.	Se conservan y se marcan. Hay que averiguar si son capturas repetidas o dos compras distintas.
Descuentos con valores raros	629 ventas tienen descuentos de 0.002, 0.202, 0.402 o 0.602, y todas son de Latinoamérica. Los demás descuentos son valores redondos, como 0.1 o 0.2.	Se marcan sin cambiarlos, porque no sabemos si son errores.
Columna Region mal llenada	Las 9,994 ventas de Estados Unidos tienen la región West.	Para comparar zonas se usa la columna Mercado.

Problema	Qué se encontró	Qué se hará
Catálogos con repetidos	En la hoja Productos, 476 filas repiten un ID de producto con otro nombre. En la hoja Regiones, cinco países aparecen dos veces.	No se combinan con la hoja de ventas hasta resolver cuál fila es la correcta.
Fechas fuera del periodo	286 entregas son de 2015. Además, el año que aparece dentro del ID Venta es el de la entrega, y en 796 ventas de fin de año no coincide con el año de la venta.	El año de cada venta se toma de la columna Fecha Salida.
Nombres con espacios de más	16 nombres de producto tienen espacios al inicio o al final.	Se crea una columna con los nombres sin esos espacios.
Información que no existe	El archivo no tiene el costo de compra de los productos, la moneda ni datos de qué se habría vendido sin descuento.	Se explica como límite del proyecto en la sección 3.9.

3.7. Plan analítico preliminar

El plan parte de lo que representa cada fila del archivo. A partir de eso se definen las dimensiones (columnas para agrupar), las medidas (columnas que se suman), las métricas (cálculos hechos con esas medidas) y el KPI.

Evento y granularidad: Cada fila de la hoja Ventas Supermercado representa una línea de pedido que es un producto dentro de un pedido de un cliente, con su descuento, su venta y su utilidad.

Dimensiones candidatas: Tramo de descuento, Categoría, Subcategoría, Mercado, País, Mes (sale de Fecha Salida), Método y Prioridad de envío. La columna Region no se usa porque en Estados Unidos todas las ventas tienen el mismo valor.

Medidas base: Ventas, Utilidad, Cantidad, Costo Envío.

Métricas. El margen por grupo se calcula como la suma de Utilidad dividida entre la suma de Ventas del grupo. También se calculan la utilidad total del grupo y la cantidad de ventas con utilidad negativa. La tasa de pérdida indica qué porcentaje de las ventas dejó pérdida y se calcula como el número de ventas con utilidad negativa entre el número total de ventas, multiplicado por 100. Los márgenes y las tasas no se suman ni se promedian entre grupos. Para cada grupo se vuelven a calcular con la suma de su utilidad y de sus ventas, porque si se promediaran, una venta de $5 pesaría lo mismo que una de $5,000.

KPI preliminar. El umbral de descuento rentable es el tramo de descuento más alto en el que el margen del grupo sigue siendo mayor o igual a cero. Quiere decir que a partir de ese umbral se pierde dinero. Los tramos que se usan son 0 %, de 1 a 10 %, de 11 a 20 %, de 21 a 30 %, de 31 a 40 %, de 41 a 50 % y más de 50 %.

Línea de pedido: Es un producto dentro de un pedido de un cliente, con su descuento, su venta y su utilidad.

Ejemplo de cómo se calcula el margen (los números son inventados, solo sirven para explicar)

Descuento	Ventas	Utilidad	Margen = Utilidad ÷ Ventas × 100
0 %	100	20	20 %
10 %	100	15	15 %
20 %	100	8	8 %
30 %	100	2	2 %
40 %	100	−5	−5 %

Conforme sube el descuento, el margen baja. En este ejemplo el umbral sería 30 %, porque es el último descuento en el que la tienda todavía no pierde dinero. Con 40 % de descuento el margen ya es negativo.

Necesidad analítica	Evento y granularidad	Dimensiones	Medidas base	Métrica o KPI y cálculo preliminar	Fuente, columnas y duda
Ubicar dónde el descuento deja de ser rentable	Línea de pedido	Tramo de descuento	Ventas, Utilidad	Margen = Σ Utilidad ÷ Σ Ventas por tramo	Descuento, Ventas, Utilidad. No se sabe si Utilidad ya resta el envío
Saber si el umbral cambia por producto	Línea de pedido	Tramo de descuento × Categoría y Subcategoría	Ventas, Utilidad	KPI umbral que es el tramo más alto con margen ≥ 0	Categoría, Subcategoría. Con 17 subcategorías algunas pueden quedar con pocas filas
Saber si el umbral cambia por territorio	Línea de pedido	Tramo de descuento × Mercado	Ventas, Utilidad	Mismo KPI calculado por mercado	Mercado. La columna Region no se usa. El margen es un porcentaje, así que no depende de la moneda, que el archivo no indica
Saber la pérdida por descontar de más	Línea de pedido	Tramo de descuento	Ventas, Utilidad	Utilidad negativa acumulada por encima del umbral y su porcentaje sobre ventas totales	Descuento, Ventas, Utilidad
Ver si el umbral se mueve con el tiempo	Línea de pedido	Mes × Tramo de descuento	Ventas, Utilidad	Margen por tramo y mes, de enero de 2011 a diciembre de 2014	Son 48 meses. Alcanzan para comparar meses, pero no para hacer pronósticos

Preguntas analíticas secundarias

1. ¿Cómo cambia el margen conforme aumenta el descuento?
2. ¿El límite es el mismo para todas las categorías y subcategorías?

3. ¿El límite es el mismo en todos los mercados?

4. ¿Qué porcentaje de las ventas ocurre por encima del límite y cuánta utilidad se pierde ahí?

5. ¿Cómo cambian las ventas, los descuentos y las pérdidas mes a mes, de 2011 a 2014?

3.8. Arquitectura propuesta de la cadena BI

Ventas Supermercado- Rodrigo Ayala.xlsx → Python → ETL → PostgreSQL → SQL analítico → Power BI → decisión sobre los descuentos

Etapa	Entrada prevista	Responsabilidad	Salida o evidencia prevista
Datos crudos	El dataset de Excel	Guardarlo sin modificar y anotar de dónde salió, cuándo se bajó, qué años cubre y que no trae licencia ni diccionario	Copia en data/raw/ y el inventario de la sección 3.6
Python	Las hojas Ventas Supermercado, Regiones y Productos	Leer las tres hojas, revisar las columnas, borrar los repetidos de los catálogos y crear los grupos de descuento	Un notebook con los conteos del Excel y sus respectivas observaciones
ETL	Las tablas resultantes de Python	Hacer un script que se pueda volver a correr de principio a fin y dejarlo en tres carpetas separadas: crudo, limpio y listo para cargar	Un script que se ejecuta solo y un archivo de texto donde se anota cada vez que se corrió
PostgreSQL	Las tablas listas para cargar	Crear las tres tablas ventas con las 51,290 filas, productos con 10,292 y regiones con 147, y conectarlas por ID Producto y País	Las tres tablas creadas en la base de datos.
SQL analítico	Las tablas de PostgreSQL	Escribir una consulta por cada pregunta secundaria, que agrupe por grupo de descuento, categoría, subcategoría, mercado o mes y saque el margen	Cinco consultas guardadas en la carpeta sql/, una por cada subpregunta
Power BI	Los resultados de esas consultas	Conectar Power BI a PostgreSQL y armar las gráficas que muestran en qué descuento el margen llega a cero, por subcategoría y por mercado	Un reporte con el límite de descuento por subcategoría y por mercado
Decisión	Las gráficas del reporte de Power BI	Definir hasta qué descuento conviene llegar en cada subcategoría y mercado, y dejar anotado lo que no se puede afirmar	Una hoja con los límites propuestos y las limitaciones del análisis

3.9. Riesgos, límites y dudas abiertas

Riesgo o duda	Evidencia disponible	Efecto posible	Cómo y cuándo se atenderá
El archivo no dice qué licencia tiene	El GitHub no lo especifica	No se puede subir al repositorio con seguridad	La profesora autorizó usar el archivo.
No hay diccionario de datos	El archivo solo trae una hoja guía de cinco renglones	No se sabe si a la Utilidad ya le restaron el envío. Si no se lo restaron, el margen real es menor y el límite podría bajar	En el avance 2 se calcula el margen de dos formas, con la utilidad como viene y restándole el costo de envío, para ver si el límite cambia
No se conoce la moneda	Hay 147 países, pero no se especifica la moneda	Los montos de países distintos podrían no compararse bien	Se trabaja con el margen, que es una división y no depende de la moneda.
Catálogos con repetidos	476 productos repetidos y 5 países repetidos	Algunas ventas salen infladas	Se limpian en Python y se revisan los totales antes de cargar a PostgreSQL
Los datos son viejos	Van de 2011 a 2014	No sirven para hablar del mercado actual	Las conclusiones se limitan a esos años
Mismo producto dos veces en un pedido	76 filas (38 pares) con el mismo pedido y producto, pero con valores distintos	Si son capturas repetidas, las ventas y la utilidad de su tramo salen más altas de lo real	Se marcan en el avance 2 y se pregunta a alguien que conozca el proceso
Descuentos con valores raros	629 ventas de Latinoamérica con descuentos de 0.002, 0.202, 0.402 o 0.602	Si son errores, esas ventas quedan en el tramo equivocado. Por ejemplo, 0.202 cae en el tramo de 21 a 30 %	Se marcan y se revisa si cambian el límite de Latinoamérica
Columna Region mal llenada	Las 9,994 ventas de Estados Unidos dicen West	Comparar por región daría resultados falsos	Se usa la columna Mercado
Confundir relación con causa	El archivo solo tiene las ventas que sí ocurrieron	No se puede saber cuánto se habría vendido con menos descuento	Las propuestas se limitan a poner topes en los tramos donde se pierde dinero
Datos personales	El archivo trae nombres e ID de clientes	Si fueran personas reales, se expondrían sus datos	Esas columnas no se usan en el análisis ni en el reporte

Preguntas que hay que hacerle a alguien que conozca el proceso

¿La utilidad ya tiene restado el costo de envío? ¿En qué moneda están los montos? ¿Los descuentos de 0.202 o 0.602 son errores de captura? ¿Las filas con el mismo pedido y el mismo producto son registros repetidos o compras distintas?

3.10. Conclusión de viabilidad y siguientes pasos

El proyecto es viable con los datos encontrados, con limitaciones. Parte de la pregunta principal sí puede atenderse. Con Descuento, Ventas y Utilidad se saca el margen por grupo de descuento y se ve dónde deja de ser positivo. Con Categoría,

Subcategoría y Mercado se compara ese punto entre segmentos. Con Fecha Salida se revisa mes a mes, de 2011 a 2014. Son 51,290 filas y no falta ningún dato. En los cuatro mercados que se analizan quedan 41,019 filas, así que las cuentas salen estables.

No podemos saber cuánto se habría vendido con un descuento menor, porque el archivo solo registra las ventas que sí ocurrieron. Tampoco conocemos el costo de compra de cada producto ni los gastos de operación, así que la utilidad del archivo no es la ganancia final de la empresa. Además, no se pueden comparar montos entre países mientras no se sepa la moneda, y no se puede hablar del mercado actual porque los datos terminan en 2014.

El proyecto es manejable con las herramientas del curso ya que el archivo es una tabla normal no muy grande. Se puede recorrer toda con Python, ETL, PostgreSQL, SQL y Power BI en el semestre sin necesitar nada más.

Antes de interpretar resultados hay que resolver tres cosas: saber si la Utilidad ya trae restado el envío, limpiar los repetidos de productos y regiones, y decidir qué margen mínimo se usa como referencia.

Siguientes pasos (semanas 5 a 8)

En las siguientes semanas se leerán las tres hojas con Python y se revisarán las 35 columnas una por una. Después se revisarán los 76 registros con pedido y producto repetidos y los 629 descuentos con valores raros. También se crearán los tramos de descuento y la columna del mes, y se separarán las ventas de los cuatro mercados. Al final se comprobará que la suma de ventas y de utilidad sea la misma antes y después de preparar los datos, para asegurar que no se perdió ni se duplicó información.

Anexo A. Lista completa de columnas de la hoja Ventas Supermercado

Columna	Tipo	Qué significa	Ejemplo o rango	Observaciones
Número Venta	Número entero	Número del pedido que aparece al final del ID Venta	0 – 5,994,251	El mismo número se repite en países distintos, así que por sí solo no identifica el pedido
ID Venta	Texto	Clave del pedido, formada por país, año y número	AL-2011-2040	Hay 25,086 pedidos. El año que aparece es el de entrega
Mes Salida	Número entero	Mes en que se hizo la venta	1 – 12	Se obtiene de Fecha Salida
Dia Salida	Número entero	Día del mes en que se hizo la venta	1 – 31	Se obtiene de Fecha Salida
Año Salida	Número entero	Año de la venta	2011 – 2014	Ninguna
Fecha Salida	Fecha	Fecha completa de la venta	01/01/2011 – 31/12/2014	Ninguna
Dia Semana Fecha Salida	Número entero	Día de la semana de la venta	1 – 7	No viene explicado. Revisando las fechas, 1 es lunes y 7 es domingo
Mes Entrega	Número entero	Mes de entrega	1 – 12	Ninguna
Dia Entrega	Número entero	Día del mes de entrega	1 – 31	Ninguna
Año Entrega	Número entero	Año de entrega	2011 – 2015	286 entregas son de 2015
Fecha Entrega	Fecha	Fecha completa de entrega	03/01/2011 – 07/01/2015	Ninguna
Dia Semana Fecha Entrega	Número entero	Día de la semana de entrega	1 – 7	Usa el mismo código que la fecha de venta
Dias Transcurridos	Número entero	Días entre la venta y la entrega	0 – 7	Ninguna
Dias laborables transcurridos	Número entero	Días hábiles entre la venta y la entrega	0 – 6	Ninguna
Método Envio	Texto	Tipo de envío	Standard Class, Second Class, First Class, Same Day	Ninguna
ID Cliente	Texto	Clave del cliente	TB-11280	Hay 1,590 clientes. Es un dato personal
Número Cliente	Número entero	Número que aparece dentro del ID Cliente	15 – 21,925	Repite información de ID Cliente
Nombre Cliente	Texto	Nombre del cliente	Toby Braunhardt	Es un dato personal. Hay 795 nombres para 1,590 claves
Segmento	Texto	Tipo de cliente	Consumer, Corporate, Home Office	Ninguna
Ciudad	Texto	Ciudad a donde se envió	Constantine, Budapest	Hay 3,636 ciudades
Estado	Texto	Estado o provincia a donde se envió	New South Wales	Hay 1,094 valores
País	Texto	País a donde se envió	Algeria, Australia	Hay 147 países. No se indica la moneda

Columna	Tipo	Qué significa	Ejemplo o rango	Observaciones
Mercado	Texto	Zona comercial	APAC, EU, US, LATAM, EMEA, Africa, Canada	Es la columna que se usa para comparar zonas
Region	Texto	Región dentro del mercado	West, Central, North	En Estados Unidos todas las ventas dicen West
ID Producto	Texto	Clave del producto	OFF-TEN-10000025	Hay 10,292 productos
Categoria	Texto	Tipo general de producto	Furniture, Office Supplies, Technology	Ninguna
Subcategoria	Texto	Tipo más específico de producto	Storage, Paper, Phones	Hay 17 subcategorías
Nombre del producto	Texto	Nombre del producto	Tenex Lockers, Blue	16 nombres tienen espacios de más. Varios productos comparten el mismo nombre
Ventas	Número decimal	Dinero cobrado por el producto, ya con descuento	0.44 – 22,638.48	No se indica la moneda
Cantidad	Número entero	Unidades vendidas	1 – 14	Ninguna
Descuento	Número decimal	Descuento aplicado, escrito en decimal (0.2 es 20 %)	0 – 0.85	629 ventas tienen valores raros
Utilidad	Número decimal	Lo que se ganó o se perdió en la venta	−6,599.98 – 8,399.98	No se sabe si ya resta el costo de envío
Ganancia	Texto	Dice Ganancia o Perdida según la utilidad	Ganancia, Perdida	Repite información de Utilidad
Costo Envío	Número decimal	Costo de enviar el producto	0 – 933.57	No se indica la moneda
Prioridad Envio	Texto	Prioridad del pedido	Low, Medium, High, Critical	Ninguna